搜索引擎全量数据的用户画像模型研究
——设计与实证

■ 吴文瀚
上海大学图书情报档案系　上海 200444

摘　要：[目的/意义] 基于某搜索引擎 5 亿全量数据，本文设计研究年轻用户大数据画像分析的总体模型和详细的研究流程，以建立用户画像的基本方法论。[方法/过程] 借助数据分析与数据验证过程的结合，通过 KL 散度和 AIO 社会学模型选取有代表性的计算样本和标签样本，并利用 CH-Score 和 SH-Score 明确算法与相关参数，利用聚类算法，通过 TGI 解读集群数据结果，最终利用关联规则发现年轻用户的汽车需求。[结果/结论] 研究将年轻用户 18－24 岁代际分为 5 类，25－34 岁分为 4 类，以这共计 9 类群体验证模型和流程的有效性，最终完成大数据用户画像从 0 到 1 的方法论的建立，并在其中融合调研方法与大数据方法。

关键词：大数据　用户画像　研究模型
分类号：G202
DOI：10.13266/j.issn.0252－3116.2022.04.013

1　理论回顾与问题发现

用户画像本质是对目标用户进行信息分析的过程。其最早起源于商业领域，商业上出于对市场的敏感，更加关注用户，因此面向用户的信息分析得以发展[1]。在数字化影响下，基于大数据的用户画像概念开始出现。A. Cooper 等曾初步提出定义，认为用户画像是建立在数据管理之上的对用户的虚拟形象进行的描绘[2]。C. Teixeira 等将用户画像的概念延伸出与当前认知基本一致的涵义，认为用户画像是借助大数据提取特征来描述用户需求、偏好的建模分析过程[3]。国内也有研究人员对于利用大数据进行用户画像的研究进行了综述[4-6]，综述的内容整体上集中于概念和理论的探索。

在实证应用上，用户画像主要被用于医疗卫生[7]、金融[8]、零售与消费[9]和知识服务[10]等领域，研究的核心在于探讨该领域用户画像的应用突破方向与可能的价值创造。在技术方法上，计算机科学中探讨新算法和算法改进内容的较多，如聚类中主要涵盖的 K-means 算法[11]、层次聚类算法[12]、密度聚类算法等[13]，这些算法的结果高度依赖所输入的数据量级和数据维度。有研究者借助单一网站上的用户评论画像，就会出现算法结果仅反映单一数据源的特征，画像结果也受到单一数据维度的掣肘[14]。同样这一问题也反映在国内使用单一社交媒体进行的用户舆情画像的实证研究中[15]。此外，有研究将已有的理论模型在实证中改进，如在图书情报[16]和知识管理[17]领域，或是针对应用指标体系进行评价[18]。有研究者尝试使用动态社交数据开展实证分析，但在静动态数据的结合运用和静态数据的权重分级上存在一定的局限性[19]，这些结合静动态数据分析的研究在近期得到实证、应用研究者的青睐。

在研究模型上，I. Lanza-Cruz 等提出了技术层面的社交商业智能分析模型，主要用于处理流媒体和社交媒体上的数据，并应用于社交网络用户画像、用户分类等研究中[20]。赵岩在 2006 年借助数据挖掘技术，利用决策树、聚类、关联与因子分析等数据挖掘与处理方法，建立汽车潜在用户的分类模型，但使用的数据基础是调研数据[21]，可以将其理解为一种早期调研数据与大数据算法的融合。P. Taylor-West 等尝试从体系构建的角度对用户画像进行论述，认为在数字化时代，既可以通过深度访谈、调研等经典方式获得数据，也可以采用大数据的方法从互联网中获取数据，并基于此搭建了综合数据来源的用户分析理论体系和应用框架[22]，

作者简介：吴文瀚，博士研究生，E-mail：wuwenhan000@163.com。
收稿日期：2021－07－02　修回日期：2021－09－09　本文起止页码：129－141　本文责任编辑：王传清

展示了用户调研、大数据与算法相融合的新用户画像理念。

综上,目前有关大数据用户画像的研究较多,但研究主题以理论探讨、各领域综述和应用可行性探索为主,处于理论、应用探索的初期阶段。用户画像的实证应用研究以应用不同的数据源为主、以算法应用与改进和数据管理技术改进为主。总体来看,实证应用中使用的方法论较为离散,缺少综合性的、普适性的、静动态数据结合的实证应用研究框架和研究结论。数据量的采样上较少超过千万级别,未能覆盖全量用户和全维度(即某一区域或年龄段的千万用户级别以上的全部维度的用户数据)。在研究的总体模型和研究流程上,虽然大数据来源于具体业务实践,已成为普遍的认识[23],但目前的研究暂未覆盖业务数据的产生流程,缺少涵盖从数据产生到结果反馈的宏观视角下的总体模型,同时与之相应的流程也未涉及。

2 研究概述与模型设计

本研究希望通过总体的模型设计、流程设计和实证过程,论述模型和流程的构建过程,并能够指导应用操作。具体研究设计论述如下:

2.1 研究概述

本研究以用户画像与需求分析为业务目标,对年轻用户进行人群分类画像,研究不同人群的需求特征,希望基于搜索引擎的全量数据,建立具有普适性的用户画像与需求挖掘总体模型,以支持理论探索。全量数据的用户画像结论能够应用于消费领域特别是汽车行业的用户信息分析,支持企业实践。

本研究通过数据合作的方式,采用国内某搜索引擎年轻用户全量数据,涵盖数据量大、数据维度宽。该搜索引擎日均处理超过 60 亿次搜索请求、超过 100 亿次位置请求,数据业务涵盖搜索、社区、娱乐、旅游、出行、消费、金融理财等领域,包含生态与合作伙伴数据、APP 安装数据,原始数据经过处理,映射形成用户数据标签。需要说明的是,由于合作涉及相应的数据保密义务,同时本研究重点在于方法论和结论,因此在论述中不公布搜索引擎的品牌,以“某搜索引擎”或“该搜索引擎”代指。

此外,为不影响合作搜索引擎的业务开展,同时考虑到服务器负载和时间经费等因素的影响,对本研究中的全量数据进行界定:即以全部 5 亿年轻用户数据点为基础,结合时间和成本方面的考量,确保研究最终所覆盖的用户总数超过 2 000 万。全量数据所指代的是服务器中 5 亿年轻用户点和每个用户数据点所对应的大量标签。确定为 2 000 万,一方面这是目前在大数据实证应用中少有的数据量级;另一方面是经过验证发现这一量级能够准确表征 5 亿用户数据的特点。

2.2 总体模型设计

用户画像的经典模型以存在明确终点的线性分析模型为主,如 U. Fayyad 等提出的经典 KDD 模型[24],是一个起始于原始数据、结束于输出知识的线性模型,特点是经过历史验证,指导性较强。而大数据时代的数据分析具有一定的数据业务化、业务数据化的时代特征,需要从技术和业务上全面改变。本研究尝试在 KDD 模型的基础上,设计适用于目前大数据量级和大数据业务的用户分析的总体模型。

该模型具有以下特点:①分析过程是从数据到洞察再到业务的一个数据闭环。数据来源于业务、业务改进依赖于数据调整,实现以终为始的循环。②分析过程中大数据分析的方法与经典的用户调研方法是相互融合的,互为补充并相互验证。③分析过程与大数据相关技术紧密相连,又有所创新,如核心节点是数据的处理、算法的确定和结果的展示。通过科学选取、科学评价的二次循环来确认结果的准确性。对于过程中数据的选择、标签的选择、算法的应用、参数的选择等内容,均采用选取、评价的二次循环过程来确认。

总体模型由 4 个模块、12 个关键节点及若干分析内容组成。模块分别为行为数据模块、算法/算力模块、用户洞察模块以及应用/反馈模块,关键节点包含数据获取、数据控制、数据标签评价、算法与参数选择、算法与参数评价、算力运用/计算、解析与洞察、调研验证、结果可视化、业务应用、业务反馈优化以及业务新需求发现,见图 1。

2.3 研究流程设计

本研究设计的用户画像总体模型,是一个适用于科研和企业大数据用户画像的宏观模型。在每个关键节点下,有若干操作步骤,这些操作步骤均会对研究结果产生重要影响。因此,本研究针对总体模型在实证过程中的操作实施需要,设计具体的研究流程。研究流程体现使用全量大数据进行用户画像的一般过程,基于此,完成具体项目的实施。在研究流程图中,方形表示每一步的具体操作步骤,共计 13 个步骤,菱形表示验证与判断的方法和过程,共计 6 个方法/过程,见图 2。

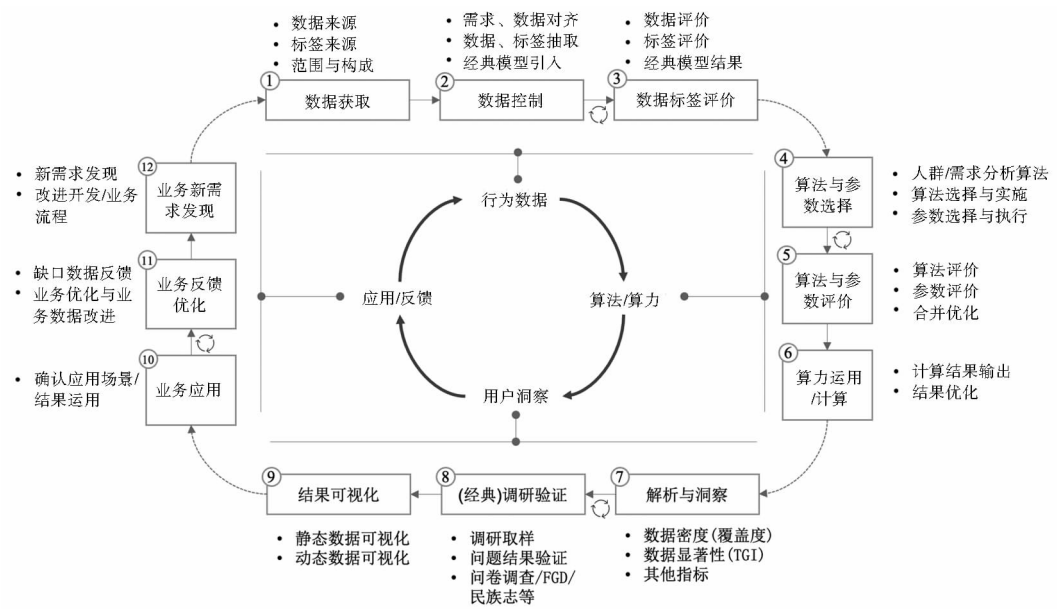

图1　用户画像分析总体模型设计

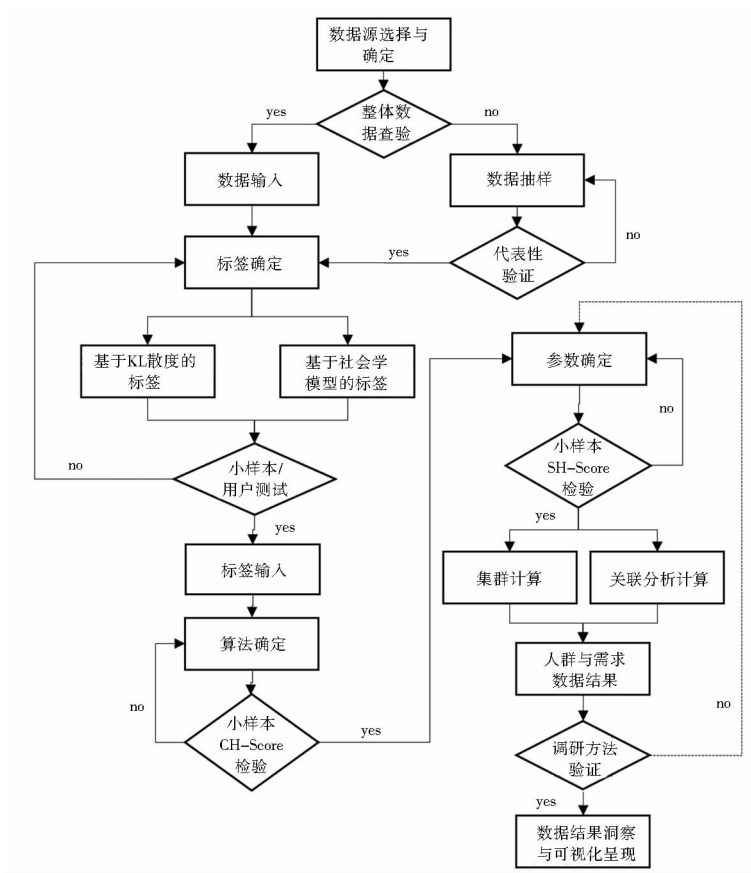

图2　全量大数据用户画像的研究流程

需要说明的是,在这个研究流程中,将调研分析作为一个验证过程,是一种创新的尝试,其目的是验证结果、同时更直观地了解用户。本研究通过12组用户的问卷调查和焦点小组讨论(Focus Group Discussion, FGD),验证数据结果的真实性与合理性,并最终得出洞察性结论。焦点小组讨论是社会学中较为成熟的方法,通过与用户以小组主题讨论的形式面对面地获得用户观点。若调研分析与大数据结果有所差异,则需

要返回集群运算环节前的关键过程，逐一查找问题。总之，通过这一流程，很好地将调查研究方法与大数据方法相互融合、相互验证。

3　实证数据

基于上述模型和研究流程的设计，进行实证研究。数据情况与处理情况如下所述：

3.1　整体数据选择与查验

本次全量数据是在该搜索引擎中选择符合年龄要求的年轻用户（18－35 岁），共计 5 亿数据点，约为该搜索引擎全部用户的 60%。将 5 亿全量数据提取后，综合评估计算时间和资源能力，最终决定以能够反映全量数据结构的数据量级（千万级）进行实际运算。

经过数据调查，该搜索引擎以数据业务为驱动，数据状态好，表现在业务中产生的数据已经过质量处理，并归类、映射到以业务、用户为分类基础的维度上。对于用户的详细特征，也已初步形成标签数据。标签数据来源于多个业务数据库的并集，经过了跨库的优化和匹配。为解决跨库数据对相同业务的不同定义问题，根据本研究的需要，数据源预先对部分数据进行统一化处理与标准转换。如“edu”标签和“income”标签，统一转换成符合国家统计局的数据界定标准的数据，减少数据中的业务含义差异，实现概念上的统一。

3.2　数据抽样与代表性验证

数据抽样基于几方面考虑：①由于与数据方合作，需整体协调项目可用的计算资源，经过对数据源的实地调查，搜索引擎提供的计算资源、开发所需人力和服务器负载的调度能够支持千万级数据计算能力。②抽样的目标是保证样本与数据总体分布一致，以准确反映全量数据的特点。实证研究需要以完成项目为首要目标，因此最终以千万量级数据实施计算，以提高效率、降低运算量与计算时间。

根据实证研究目标，将年轻用户分为 18－24 岁、25－34 岁两个独立的代际，在服务器中选取出相对应的用户数据点共计 5 亿。通过随机抽样算法，取出两组各1 000万数据点集合，分别验证其对于总体样本和总体标签的代表性，最终在保证实验总样本符合 5 亿样本分布的前提下，研究数据点超过 2 000 万。样本代表性和有效性验证结果如图 3 所示，5 亿用户在 97.5% 的置信水平下，1 000 万抽样量的误差率低至 0.031%，误差率在抽样量级提升后也没有明显下降，证明抽样量可代表该项目的全量 5 亿用户。

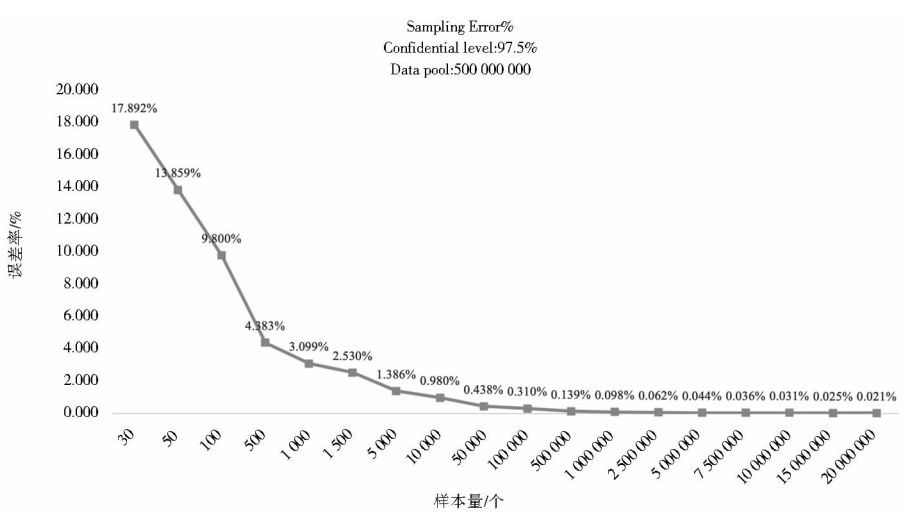

图 3　50:1 情况下样本量误差率验证

为确保抽样数据点与总体标签的一致性，本研究对其进行代表性验证。在抽样过程中总计抽取 5 组 1 000万用户的样本集合，结合主要人口学特征标签结果，验证样本标签的代表性。通过多级标签模型提取，一级标签为 10 个：性别、年龄、行业、职业、收入水平、学历、消费水平、婚姻状态、人生阶段、拥车状态；二级标签总计 46 个，基本涵盖人口的基础信息。结果显示，在抽样率为 50:1 的情况下，将 5 组样本与总体样本进行对比，各标签的极差最大为 0.09%，未超过 0.1%；同时，5 组样本之间相互对比，平均误差也不超过0.018%，足证抽样量及标签量可以代表 5 亿全量。如表 1、表 2 所示：

表1　50:1抽样情况下标签验证

（单位:%）

与全样本误差范围	1 000万抽样1	1 000万抽样2	1 000万抽样3	1 000万抽样4	1 000万抽样5
性别	－0.006－0.006	－0.012－0.012	－0.008－0.008	－0.018－0.018	－0.027－0.027
年龄	－0.019－0.019	－0.011－0.012	－0.012－0.018	－0.038－0.022	－0.012－0.011
行业	－0.013－0.020	－0.018－0.026	－0.011－0.014	－0.023－0.016	－0.019－0.013
职业	－0.026－0.020	－0.022－0.039	－0.021－0.014	－0.018－0.020	－0.013－0.025
收入水平	－0.024－0.014	－0.019－0.025	－0.024－0.017	－0.018－0.022	－0.034－0.029
学历	－0.009－0.005	－0.015－0.025	－0.009－0.009	－0.018－0.009	－0.006－0.004
消费水平	－0.030－0.027	－0.011－0.009	－0.032－0.044	－0.016－0.019	－0.022－0.011
婚姻状态	－0.021－0.021	－0.009－0.009	－0.007－0.007	－0.023－0.023	－0.014－0.014
人生阶段	－0.023－0.023	－0.024－0.024	－0.045－0.045	－0.031－0.031	－0.029－0.029
拥车状态	－0.016－0.016	－0.005－0.005	－0.013－0.013	－0.008－0.008	－0.006－0.006
极差	0.057	0.061	0.090	0.062	0.063

表2　5组样本间对比情况

（单位:%）

平均误差	1 000万抽样1	1 000万抽样2	1 000万抽样3	1 000万抽样4	1 000万抽样5
1 000万抽样1		0.014	0.016	0.016	0.015
1 000万抽样2	0.014		0.015	0.018	0.014
1 000万抽样3	0.016	0.015		0.015	0.017
1 000万抽样4	0.016	0.018	0.015		0.016
1 000万抽样5	0.015	0.014	0.017	0.016	

4　实证方法与过程

实证方法和过程主要包括标签的确定与测试,算法确定与检验,参数确定与检验,集群结果输出与解读,用户需求与验证5个主要部分。

4.1　标签确定与测试

确定模型输入标签是算法的关键内容,对于多数算法来说,输入的内容决定了算法边界,本研究尝试建立相对量化的标签筛选体系。

4.1.1　基于KL散度的标签体系

对于大数据和计算集群来说,由于跨数据库、跨业务体系、跨标准形成的特征标签众多,如何从中获取对分析有价值的标签较为重要。KL散度(Kullback-Leibles Divergence)可以理解为两个概率分布间距离的度量[25]。

本研究尝试基于KL散度指标建立初步的标签体系。通过KL散度,分别以年龄段内的人群作为正样本,年龄段外的人群作为负样本,计算特征的KL－正负散度和KL－负正散度并对其做相应的平滑处理。KL散度越大,信息增益越强,表明该特征越能够区分出不同年龄段间用户的特征表现,也就证明越具有区分性,借此选出具备高区分性的特征标签。在特征标签的层级筛选上,为保留细节,将其展至四级标签。信息熵与条件熵的差值即为信息增益。KL散度核心式[26]表达如下:

$$D_{KL}(p \parallel q) = \sum_{i=1}^{N} p(x_i) \cdot \log \frac{p(x_i)}{q(x_i)} \qquad \text{公式(1)}$$

其中,$p(x)$是目标分布,$q(x)$是匹配分布,若两者完全一致,则:

$$D_{KL}(p \parallel q) = 0$$

通过KL散度计算结果,将信息增益平滑后将0.05及以上的特征标签输出,在两个年龄段(18－24岁、25－34岁)分别筛选出特征标签共计5 078个和4 754个,作为高区分型特征标签集合,见表3。

初步结果显示,若完全基于KL散度,则会出现一些标签强度较大,对聚类结果的支持效果不佳。主要表现在:①基于高区分特征标签的聚类结果过于强调人群的区分性特征,导致影视音乐类的特征在结果中过于显著;②基于高区分特征标签的聚类结果会放大一些覆盖人数相对较少的特征,产生偏差。为解决上述问题,在高区分性特征标签基础上,引入社会学模型框架。

4.1.2　引入AIO模型框架的标签体系

AIO模型框架是社会学进行用户分类的基础框架,早期由J. Plummer等创建,是对用户生活方式的分析。目前测量生活方式应用广泛的AIO量表,是通过对W. Wells和D. Tigert于1971年成果的提炼得来的[27]。基础的AIO模型框架包含3个维度,活动(Activities)是用户的行为表现,兴趣(Interests)是用户的

表 3 高区分特征的标签举例

年龄段	序号	特征	覆盖人数	信息增益 * 1000
18 – 24 岁	1	marriage_未婚	3 178 144	264.58
	2	consumption_低	6 982 836	249.96
	3	life_stage_学生	708 159	76.87
	4	教育培训_考试培训_四六级培训	291 524	58.09
	5	car_无车	8 696 925	45.53
		……		
	5 078	个护美容_个人护理_脱毛	48 447	0.05
25 – 34 岁	1	consumption_中	5 671 820	76.97
	2	母婴亲子_宝宝玩乐_玩具	1 395 158	63.32
	3	影视音乐_动漫_类型_[动画]	1 662 896	57.28
	4	影视音乐_动漫_关注动漫_[汪汪队立大功]	1 119 357	55.53
	5	影视音乐_动漫_类型_[亲子]	2 402 369	53.99
		……		
	4 754	影视音乐_电影_关注导演_[timmiller]	26 337	0.05

意愿表现，意见（Opinions）是用户的态度及价值观的表现。具体如表 4 所示：

表 4 AIO 模型框架的基本内容

人口统计变量	活动	兴趣	意见
年龄	爱好	家庭	自己
性别	度假	家事	社会议题
教育	工作（学习）	工作	政治
所得	购物（消费）	社区	商业
职业	社交	消遣	经济
家庭人数	社区（生活）	流行	教育
居住地	运动娱乐	食物	产品
城市大小	金融财经	媒体	未来
家庭生命周期	汽车	成就	文化

通过引入 AIO 模型框架，使计算使用的标签体系更贴近用户的行为。基于上述 KL 散度得到的 5 078 和 4 754 个标签，结合小范围招募的用户反馈，确认与 AIO 框架维度相一致的标签作为最终标签体系。同时，对数据源标签层级的展开深度进行区分，形成了基于两个年龄段的 ABCD 四套标签组合，通过比较聚类结果，判断得出更优的标签结果体系。

标签组 AC 是两个年龄段由一级、二级标签组合而成的标签，各由 386 个标签构成；标签组 BD 是两个年龄段由一级至四级标签组合而成的标签，分别由 1 617和 1 609 个标签构成，如表 5 所示：

表 5 标签维度与统计

标签	Count of 标签组 AC		Count of 标签组 BD	
	18 – 24 岁 标签组 A	25 – 34 岁 标签组 C	18 – 24 岁 标签组 B	25 – 34 岁 标签组 D
人口统计变量_家庭生命周期	4	4	4	4
人口统计变量_居住地	37	37	37	37
人口统计变量_性别	2	2	2	2
人口统计变量_所得	9	9	9	9
人口统计变量_教育	3	3	3	3
人口统计变量_职业	29	29	29	29
活动_工作（学习）	27	27	176	169
活动_度假	66	66	150	150
活动_汽车	28	28	330	329
活动_爱好	34	34	84	85
活动_社交	33	33	154	157
活动_社区（生活）	29	29	220	219
活动_购物（消费）	35	35	155	151
活动_运动娱乐	21	21	141	141
活动_金融财经	29	29	123	124
总计	386	386	1 617	1 609

4.2 算法确定与检验

算法主要从理论与实践研究中使用较多的 K-means、WARD 层次聚类、谱聚类 3 种算法中进行选择。从两组 1 000 万 + 的数据中各科学地抽取出 10 万数据点，用以确定算法。对 3 种算法的轮廓系数（SH-score）进行比较。轮廓系数表示聚类后各类样本间的紧密程度和各类之间的离散程度[28]。假定将待分类数据分成“n”个簇，对于簇中的每个向量，分别计算它们的轮廓系数进行比较。具体表达如下：

$$S(i) = \frac{b_i - a_i}{max\ \{a_i, b_i\}} \qquad \text{公式(2)}$$

其中，a_i 是样本 i 到所属类别中所有样本的平均距离；b_i 是样本 i 与它最近的不同类别中所有样本的平均距离 。

轮廓系数的值介于[– 1，1]之间，趋近于 1 代表内聚度和分离度都相对较优。将所有点的轮廓系数求平均，就是该聚类结果总的轮廓系数。考虑聚类结果的合理性、可操作性和可理解性，聚类初始值不宜过高或过低[16]，对 3 – 20 类聚类结果使用 SH-score 进行评价。

结果发现，对于 ABCD 共 4 套标签体系，在 3 种算法比较得分上，K-means 方法在 3 – 20 类聚类结果中相对于层次聚类和谱聚类较优。同时，K-means 为聚类算法中应用较为成熟的一种，鲁棒性较强，因此最终确定借助 K-means 算法进行人群的划分，如图 4 所示：

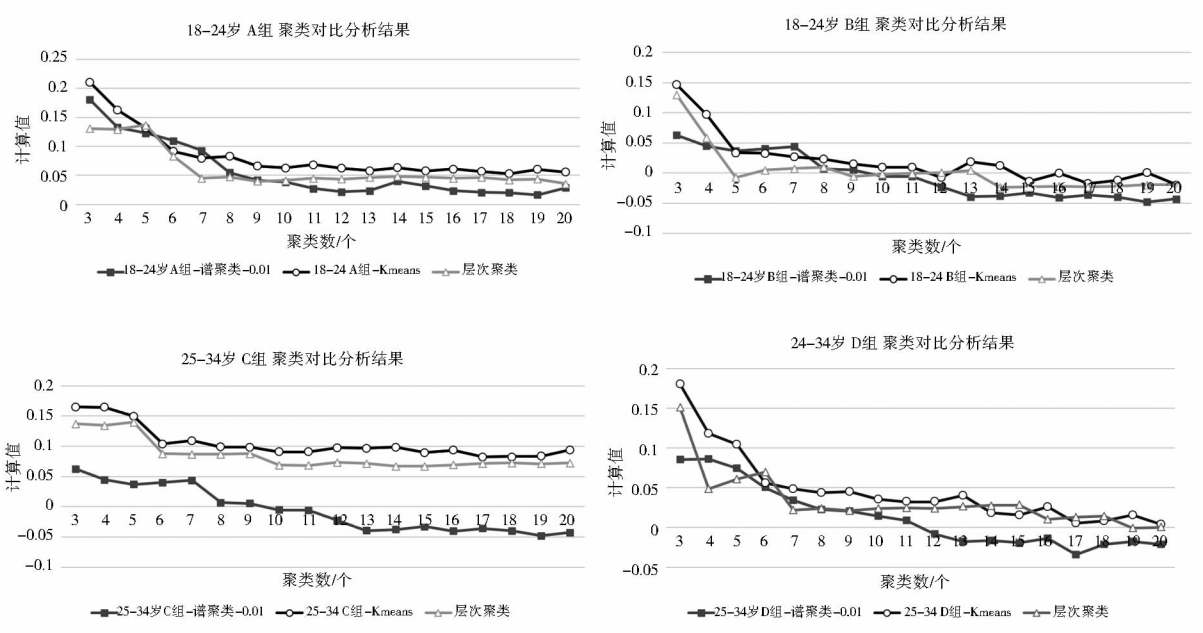

图 4　4 组聚类结果 SH-score 对比

K-means 算法的基本理念是通过计算每个数据点与簇中心的距离,进行划分式分类。算法的输入值为数据对象和初始聚类个数,即算法 K 值;算法输出的是能够使平方误差准则最小的 K 个聚类簇。黄韬等对 K-means 算法进行过详细论述[29],核心表达如下:

$$d(i,j)=\sqrt{(x_{i1}-x_{j1})^2+\cdots+(x_{in}-x_{jn})^2} \qquad \text{公式(3)}$$

其中 $i=(x_{i1},x_{i2},\cdots,x_{in})$,$j=(j_{i1},j_{i2},\cdots,j_{in})$ 是两个 n 维数据对象。比较数据对象间的距离,利用平方误差准则使聚类结果尽可能地独立和紧凑。

4.3　参数确定与检验

对于 K-means 聚类算法,初始值的选择相对重要。对于 K 值的选择目标是既要保证最终的人群结果便于分析和业务洞察使用,又需要在技术层面上确保研究的合理性。综合上述内容,本研究采用 CH-score 与 SH-score 相结合的方法来确定聚类算法的初始结果。数据依然采用科学抽样得到的涵盖各年龄段的 10 万数据为代表进行研究。这里引入 CH 分数辅助判断 K 的最优取值。CH 分数指标是 Caliński Harabaz 提出的评价聚类结果的指标。原理同样是基于类内距离和类间离差矩阵的测度。值越大表示聚类结果的类内距离越小而类间距离越大,聚类结果性能越好,反之则较差[30]。

轮廓系数的取值范围为[－1,1],CH 分数没有取值范围,定义如下:

$$s(k)=\frac{tr(B_k)}{tr(W_k)}\frac{m-k}{k-1} \qquad \text{公式(4)}$$

其中,m 为训练集样本数,k 为聚类个数,B_k 为类别之间的协方差矩阵,W_k 为类别内部的协方差矩阵,tr 为矩阵的迹。

综合数据结果来看,在以 K-means 方法聚类的过程中,CH-score 和 SH-score 的得分均随着聚类数量的增加而呈现线性减少的趋势,理论上的最优聚类结果可能应用效果并不好。因此,这里以 CH-score 为主,当 CH-score 变化不明显时,综合考虑 SH-score 结果,引入“手肘法”来进行对比判断。即找到 CH-score 和 SH-score 的某个 K 点满足下列条件:K＋1 时,score 相比 K 出现了剧烈下降,这表明 K＋1 值聚类效果出现明显下降;K－1 时,score 相比 K 变化相对平缓,这表明 K－1 值与 K 值聚类效果类似,具体情况见图 5。

最终确认聚类结果判断如下:

在 18－24 岁、A 组,评价得分的 K 值在第 7 组出现明显下滑,取 K 值为 6;在 18－24 岁、B 组,CH-score 得分在第 6 组出现明显下滑,取 K 值为 5;在 25－34 岁、C 组,整体评价得分相对平缓下滑,CH-score 得分在第 5 组、第 6 组时出现明显下滑,考虑到 SH-score 到第 6 组下滑明显,取 K 值为 5;在 25－34 岁、D 组,同理综合考虑 CH-score 和 SH-score 得分,选择 K 值为 5。

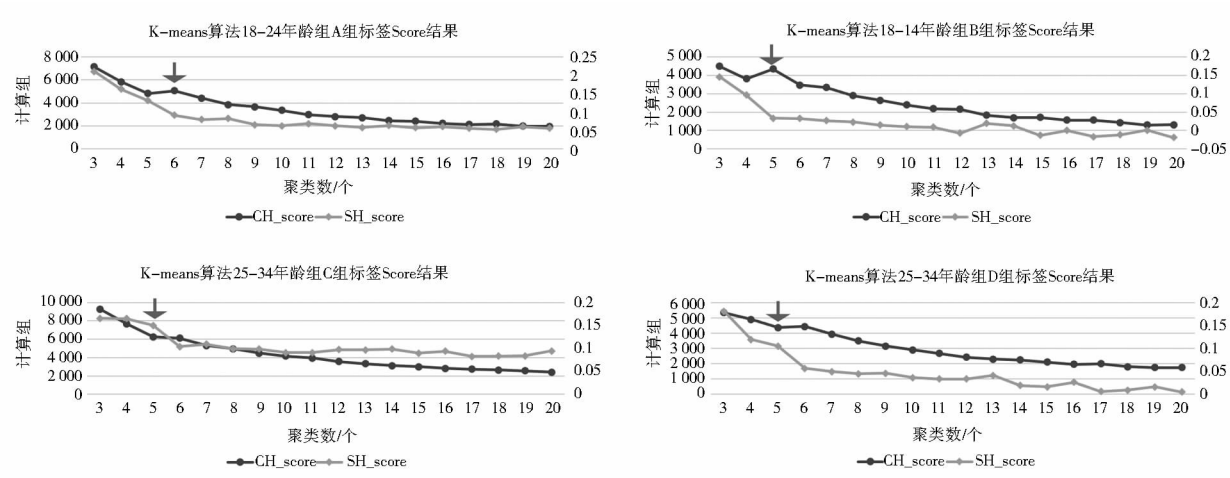

图 5　K-means 算法下 K 值的选择与检验

将两个年龄段、标签组合成的 4 次聚类结果进行输出并比较，可以发现，BD 两组标签集合的结果标签细节多、深度较好，但详细的三级标签输入对人群分组未产生正影响，反而会对模型产生噪音，三级标签进行分类的作用未得到体现。其次，使用层级较多的三级标签分类，稀释了总样本，使“各方面信息关注均较低”的人群占总体的比例有所提升，对模型产生噪音，弱化群组间的差异性。因此，在进行全量样本用户画像时，数据的维度比数据的细节更加重要，数据的维度有利于增加用户区分度，便于获得业务层面的洞察。因此，集群聚类结果将基于 AC 标签组各 386 个标签进行，K-means 聚类算法初始聚类数为 18－24 年龄段 6 类，25－34 年龄段 5 类。

4.4　集群结果输出与解读

综合上述相关结果，将标签体系、算法和参数纳入集群对 2 000 万用户数据点进行聚类运算，得到集群结果。

18－24 岁代际得到 6 类聚类数据结果，覆盖 9 413 429个用户点；25－34 岁代际得到 5 类聚类数据结果，覆盖 1 289 406 个用户点。其中 18－24 岁代际的人群因数据四舍五入、保留整数等原因总计为 99%（下同），具体情况如表 6 所示：

表 6　聚类结果分布情况

18－24 岁代际	A1 群体	A2 群体	A3 群体	A4 群体	A5 群体	A6 群体	总计
数据点/个	1 928 976	2 668 445	1 165 589	1 306 118	1 799 895	544 406	9 413 429
占比/%	20	28	12	14	19	6	99
25－34 岁代际	C1 群体	C2 群体	C3 群体	C4 群体	C5 群体	–	总计
数据点/个	3 706 943	1 815 596	4 208 486	2 136 679	941 702	–	12 809 406
占比/%	29	14	33	17	7	–	100

借助覆盖度和显著性指数（Target Group Index，TGI）两个指标对聚类结果进行解读。覆盖度主要表征人群中某一行为特征的多少，计算方法为本人群中含有该标签的人数与本人群总人数的比值。显著性指数主要表征本人群与其他人群的差异程度，计算方法为本人群中某一标签的占比与代际下该标签的占比的变化度[31]。

设群体 $B(B \in I)$，$card(I)$ 为群体特征总体数，具体特征 A 的群体覆盖度和 TGI 为：

$$覆盖度（Coverage）=\frac{card(A)}{card(I)} \qquad 公式(5)$$

$$显著性（TGI）=\frac{card(A \cap B)}{card(B)} \Big/ \frac{card(A)}{card(I)}-1 \qquad 公式(6)$$

若以显著性指标为横轴，覆盖度指标为纵轴，可形成不同人群判断解读的差异化象限，并对人群的数据结果和人群特点进行解读。

在数据结果中，两个年龄代际中均存在一部分特征不活跃的聚类数据结果，需要对这部分内容予以修正。特征表现为：①特征标签覆盖度和 TGI 指标远低于人群和代际的平均水平。如 A2 群体在通讯聊天标签的覆盖度为 12%，平均水平为 60%，与平均水平差异较大。②除硬件预装常用 APP 外无其他 APP 的安

装。③文件管理、文件浏览器类的安装超过平均水平。综合上述①－③,设备使用情况远低于平均水平,较少安装新 APP 等特征标签指向备用机、电视盒子等设备号,将这部分结果从人群分类中剔除。经验证,A2 群体与 C1 群体主要由设备号数据构成,将这部分数据进行剔除,并利用国家统计局数据,对剔除设备号后的人群按比例还原。还原后的数据四舍五入取整数如表 7 所示:

表 7　剔除设备号后的用户群体

18－24 岁	A1 群体	A3 群体	A4 群体	A5 群体	A6 群体	总计
占比/%	29	17	19	26	8	99
25－34 岁	C2 群体	C3 群体	C4 群体	C5 群体		总计
占比/%	24	46	20	10		100

4.5　用户需求与验证

4.5.1　用户需求结果

基于聚类后的各类人群,每一类人群中均采用关联规则方法,寻找各特征之间的关联性,作为需求分析的数据。由于人群数量和计算量较大,选择抽样后再进行关联规则的输出。关联规则的意义在于更好地解释人群行为,避免错误解释。对于每类人群的特征,进行关联规则分析。计算项集之间的支持度、置信度、提升度。以项集{A,B},全记录集合 I 为例,上述概念定义为:

$$\text{支持度}\{A\rightarrow B\}=\frac{P(A,B)}{P(I)} \qquad \text{公式(7)}$$

$$\text{置信度}\{A\rightarrow B\}=P(B\mid A) \qquad \text{公式(8)}$$

$$\text{提升度}\{A,B\}=\frac{P(B\mid A)}{P(B)} \qquad \text{公式(9)}$$

由于关联规则是具有方向性的,按照 B 项集覆盖度较高、置信度不等于 0 或 1、提升度较高的规则,筛选出强关联规则的结果所对应的标签,作为该人群的显著特点。最终,输出 18－24 岁代际关联分析结果 538 508条,计算结果中选取大于 1.5 的 16 万条数据;25－34 岁代际关联分析结果 455 357 条,计算结果中选取大于 1.5 的 13 万条数据,剔除标签间重复部分。集群结果的解读和基于关联规则的用户需求结果共同构成需求洞察的基础。

4.5.2　数据结合调研的需求验证

在集群数据结果和群体需求确定后,结合下述用户座谈会为主的用户调研方法,可以实现对用户群体和需求的二次验证。在需求的验证方法上,经典的用户调研(包含问卷调研、用户座谈会、焦点小组等形式)具有反馈直观、表述直接的特点,通过数据分析与用户调研相结合,实现大数据支持调研、调研验证数据结果的方法创新。

本研究将大数据研究方法与经典的用户问卷调研和访谈法进行充分的融合,具体来说主要是两方面内容:一方面,利用大数据聚类结果筛选出调研所需要的受访用户。在数据聚类结果基础上建立由粗至细的用户筛选漏斗,选择出合适的接受访谈的人群;另一方面,通过用户直观表述验证聚类标签结果。重点是将聚类得到的标签数据和存疑的数据在访谈中进行验证,以确认用户行为背后的真实需求,同时一些与常识相悖的数据内容也在调研过程中进行深入挖掘,以获取新的发现。本研究总结了“被访人群特征转换列表”,基于这一列表寻找对应的人群,并借助座谈会挖掘相应人群行为背后的需求,实现对用户的业务洞察。这一转换方法也具备跨行业和项目的通用性。其中,部分特征转换举例如表 8 所示:

表 8　被访人群特征转换列表(部分)

	人群大数据结果	调研样本筛选条件
性别	男 55%,女 45%	男女 1:1
婚否	未婚占比 91%	每 10 人中至多 1 个已婚配额
……	……	……
金融信息	拥有金融证券 app 占比 40%	手机端装有金融、证券 app(不含手机银行);近一年关注股市等,至少 2 人能提供开户证明(涉及股票/债券/外汇等)
出行信息	远途出行用户占比 91%,其中飞机出行用户占比 50%	最近 6 个月完成远途出行方式中,选择飞机出行,提供机票证明

本研究使用用户调研中的用户座谈会方法。共计召开 12 组座谈会,每组 10－12 人,其中 18－24 岁代际 6 组,25－34 岁代际 6 组。经过用户调研方法验证,用户群体的划分与实际用户所表述的内容基本一致。同时,本研究选择汽车消费作为具体领域的突破点,在访谈时验证用户在消费特征、购车触发点、汽车诉求上的具体表述,与大数据聚类结果中的特征标签表现进行比对,优化部分结果与表述后发现,数据结果与用户表述能够在最大程度上相互验证。

5　结果与洞察

人群结果概览是对用户进行总体性描述。将已进

行覆盖度和显著性分析的数据结果分为兴趣偏好、基础属性、人群特征、消费特征、购车触发点、汽车诉求和其他诉求几个主要维度进行解析，最终将人群中 18－24 岁代际分为 5 类，25－34 岁代际分为 4 类，描述如图 6 所示。过程如下：首先，以基础属性标签和活动标签为基础，对群体社会属性和活动行为特征进行描述，通过与总体进行对比，形成兴趣偏好、基础属性等数据内容。其次，将用户聚类的标签结果，结合用户座谈会结果，总结出不同人群显著的人群特征和消费特征等内容，精炼人群的名称定义。最后，以词云图、蛛网图等清晰的形式将人群的标签和数据特点进行展示，输出可视化结果。

	18-24岁代际					25-34岁代际			
	A1:逐梦凡客 21%	A3:安逸平淡 12%	A4:活力四射 14%	A5:庸碌克己 19%	A6:品质优渥 6%	C2:负重前行 17%	C3:平碌现实 33%	C4:闲逸惬怡 14%	C5:品质精英 7%
兴趣偏好	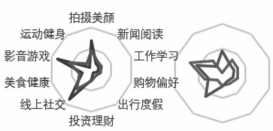								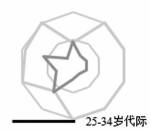
基础属性	3+4线城市 46%	重点+1线 35%	1线+2线 54%	3线＋4线 47%	重点＋1线 50%	重点＋1线 33%	3+4线城市 47%	3+4线城市 46%	重点＋1线 50%
	大专及以下 98%	本科及以上 10%	本科及以上 9%	大专及以下 96%	本科及以上 25%	本科及以上 12%	大专及以下 96%	大专及以下 93%	本科及以上 37%
	低收入 72%	中+低收入 83%	中+低收入 85%	中+低收入 87%	高收入 29%	中等收入 23%	中等收入 27%	中+低收入 80%	高收入 39%
	中+低消费 95%	中+高消费 41%	中+高消费 39%	低消费 67%	高消费 16%	中+高消费 62%	低消费 51%	中消费 43%	高消费 39%
	已婚 27%	已婚 20%（-）	未婚 81%	已婚 30%	未婚 91%	已婚 73%	未婚 32%	已婚 78%	未婚 41%
	有孩 4%	有孩 5%	学生 18%	有孩 2%（↓）	有孩 2%（↓）	有孩 28%	有孩 11%（-）	有孩 40%	有孩 26%
人群特征	现实社会的边缘群体，需要寻求存在感	日常生活平淡	对未来充满希望	工作（学习）受约束，无暇享乐	体现出优越感的个性化与多元化生活	事业上升期，来自各方压力大	生活窘迫，隐匿于线上社交	进入平稳期，全部希望寄托于下一代	不断进取保持领先
	空闲时间多，多依赖线上娱乐等消磨时间	安逸于现状，偶尔享乐生活	勇于尝鲜、尽情体验多样生活		自我主动提升意愿高	收敛个性，家庭成为生活重心	丧失欲望，缺少奋斗方向	空闲时间较多，通过生活中的小乐趣满足自我	拥有丰富多彩的生活，且保有上进的无限潜力
消费特征	• 物欲较强，易盲从网购促销，换取消费快感 • 通过“最小化犒赏”步步为营的消费观念	• 日常消费趋于理性，较为经济的享乐 • 对于特定商品，有购买冲动	• 愿意超前消费换取自我满足的体验	• 物欲水平显著低	• 更加倾向选择豪华品牌 • 追求高品质化消费	• 提升子女生活品质舍得投入 • 达到一定收入水平后，有品质升级的要求	• 消费观念消极 • 实现较高收入后，有向上升级的消费诉求	• 高性价比消费态度 • 关注消费能够带来别人的重视或尊重	• 重视品牌 • 有品味的消费
购车触发点	• 结婚是主要的购车契机			• 极低的拥车意愿	• 家庭通常有车，没有立即购车需求	• 生活水平整体提升	• 车辆兼顾生产资料和消费品双重属性	• 带来面子	• 生活必须品
汽车诉求	• 满足家庭人口增加，对空间、环保要求	• 车辆能够满足家庭出游需要 • 对环保要求较高	• 运动外观 • 更多高科技功能/配置 • 炫酷造型、同龄认可品牌影响设备			• 家庭化需求为核心 • 注重产品品质 • 理性关注车辆性价比	-	• 有面子车型 • 影音娱乐系统功能较强	• 有品位的外观内饰设计 • 有品质感 • 高科技/新能源
其他诉求	• 低门槛的金融服务需求强烈，但对有金融服务费率敏感度较低		• 结合互联网金融服务与汽车金融服务相结合，更加便捷借贷与月供服务		• 对高档次网约车/短租车有较高需求	• 品质升级过程中依赖于金融服务，但对于服务费率较为敏感	• 需要通过购车金融支持，对月供金额更加敏感	• 汽车租赁服务，满足旅行要求 • 品牌被广泛认知，具有社交属性	• 汽车租赁服务，满足旅行要求 • 高品质新能源车，满足社会责任感

表格中信息均表示高于总体，仅（-）表示与总体持平，（↓）表示低于总体

图 6　人群结果概览

6　总结与展望

6.1　实证结论与模型指导性

从实证的结果看，基本能够表现用户画像的效果。这体现在两个方面，其一是在调研用户的直观表述中，同一人群中的用户所表述的特征与群体特征一致；其二是在横向比较中，本研究的用户画像结果与知识管理用户画像[16－17]及不同群体的老年人群用户画像[32]的结果类似，并有更加精细化的效果，如表 9 所示：

表 9　实证结果间的横向对比

项目	本研究用户画像	其他画像 1	其他画像 2	其他画像 3
总数据量/人	22 222 835	869	7 512	8 074
划分群体数/个	9	4	4	8
标签/问题数/个	386	13	15	46
其中：基础信息/个	84	4	N. A.	13
其中：活动信息/个	302	9	N. A.	33
解析维度大类/个	16（不含定性）	4	5	7

实证验证了研究模型的有效性。一方面,基于用户画像模型,本研究的实证部分完成了模型中从数据获取到可视化的内容,除应用/反馈模块外,基本逐一实现了模型对实证的具体指导。对于研究流程来说,也完成了从数据输入到结果呈现的实施与验证流程。既说明了总体模型的指导意义,也论证了研究流程的操作指导价值,未来的大数据用户画像,可以采用这一流程进行研究。另一方面,从完整性来说,研究模型的完善仍然需要实现最后一步的闭环,即业务结果反馈至业务实践,并由业务实践获取新的业务数据的过程。这一步需要结合业务予以完善,包括对于业务流程的改进、业务数据获取、直连用户、用户触点与用户业务激活等各方面内容。

从实证的结论来看,结论对于用户信息分析,特别是汽车用户需求的宏观和微观把握有较大帮助,如可指导汽车行业用户画像和产品定位。展望未来,中国经济整体处于长期向好的阶段,两个代际下不同群体的年轻人都将形成消费升级期望。在基盘(A1/A5/C3 群体)中,竞争将更加激烈,用户的选择也更多,需要基于不同目标人群的详细特点,以制定详细的产品服务策略,满足需求。中下层(A3/A4/C2/C4 群体)在汽车消费上呈现出拉长现有车辆使用期限、小幅提升车辆档次等行为。年轻人双向诉求(品质向上与高性价比)间的碰撞将更加激烈,通过建设汽车品牌的高品质形象,并结合创新技术、功能在汽车品牌上的导入,可拉动潜在机会市场。对于上部(A6/C5 群体)来说,新能源和智能化技术将成为突破重点,“新能源”“智能”“新科技”能够树立进取的精神形象,作为前沿科技潮品,增加该群体的购买欲望。

6.2 研究总结

总结来看,本研究将离散的数据分析方法论借助实证进行系统的整合,设计了基于搜索引擎大数据的用户画像理论模型,建立具体的研究流程。针对全量数据,本研究将经典 KDD 线性模型扩展延伸,构建从业务数据出发,再反哺业务的用户画像全流程闭环模型,使用户画像的方法论延伸至业务层面,加强了来源反馈。在技术上,数据聚类算法、评价算法在这一总体模型中得到精简与优化。研究流程的建立与应用,与总体模型共同构成用户画像与需求发现的实证型方法论体系,解决了从 0 到 1 的操作问题。

与其他大数据用户画像模型相比,本研究构建的模型将经典调查研究、社会学理论与大数据分析的方法论相融合,将客观数据与主观表述相互验证,使得研究过程更有效率、分析结果更易于理解和接受:一方面,利用社会学经典模型,简化全量数据中的众多特征标签,利用 AIO 模型简化 KL 散度形成的模型体系,以构成 360 度的均衡标签;另一方面,在用户需求验证方面,借助“特征转换列表”,能够精准定位用户,通过用户座谈会验证聚类结果的真实性。此外,本研究的另一个独特之处是基于数据的分析和验证的双结合。研究从大数据出发,借助数据和数据计算验证模型、参数的选择,得出数据结论,这些均是以数据和计算得到分析结果和验证结果(如在算法的确定和验证过程中,使用轮廓系数方法验证不同算法的优劣,并得出指标得分等),在过程中尽量做到数据和计算主导,规避主观因素。

本研究创新性地使用了全量数据。一方面,研究的数据基础是 5 亿数据点覆盖的全部年轻用户;另一方面,研究对特征标签进行了全覆盖,将搜索引擎母公司所涉及的全部业务标签维度,纳入研究的范畴。需要说明的是,采取有代表性的抽样出于以下考量:①由于数据源为合作方而非开发主体,需要综合考量项目的研究经费、资源占用、业务影响等多方面因素;②在数据标签上,研究中对未做精简的标签进行过计算,但结果并不理想,业务数据会影响人群聚类的效果,最终表现出的是该搜索引擎的数据分布而非人群聚类结果;③目前应用大数据分析的文献中以单一文本类、爬虫数据的分析居多,而超过千万量级用户数据的分析相对较少,本研究最终输出总计2 000万以上的数据结果,能够反映全部用户的特征(前期经过科学抽样验证、后期经过用户座谈会验证);最后,值得一提的是,对全量大数据进行分析需要在数据管理和数据优化方面有较多处理,同时也需要数据量充足的数据源进行配合。

6.3 研究局限与展望

本研究的局限主要在于对数据源的把控上。由于以数据合作方式进行,本研究对数据并没有归属权,仅有结果的使用权,因此在数据治理和质量管控上有一定的细节缺失。令人欣喜的是,在研究过程中,查验了部分业务大数据,发现研究所用到的搜索引擎数据源在业务数据的管理上较为完善,能够将数据治理深入到业务产生的源头中去,并定期根据总体用户管理的

需要进行更新调整。未来,结合数据治理的视角完善大数据用户画像的流程,是值得深入研究的内容。

在后续研究与应用中,这一方法论体系能够在新环境、新数据源下快速复制、传播。此外,实证的结果可以指导多个行业应用,如消费电子、汽车、零售等,体现研究的跨行业普适性。由于人群及其特征的变化周期相对较长,该研究的结果可以支持一类代际人口的特征判断,具有跨时间周期的通用性。同时,人群分类结果和详细汽车需求分类结果,对于汽车产业研究年轻用户的详细需求也具有一定的参考价值。

参考文献:

[1] FULLERTON A R. The birth of consumer behavior: motivation research in the 1940s and 1950s [J]. Journal of historical research in marketing, 2013, 5(2): 212 - 222.

[2] COOPER A, REIMANN R. About face 2.0: the essentials of interaction design [M]. New Jersey: John Wiley & Sons, 2007.

[3] TEIXEIRA C, PINTO J, MARTINS J. User profiles in organizational environments [J]. Campus-wide information systems, 2008, 25(3):128 - 144

[4] 化柏林, 赵辉. 用户画像方法在科技情报需求探测中的应用探讨 [J]. 情报理论与实践, 2020, 43(9): 93 - 99.

[5] 赵雅慧, 刘芳霖, 罗琳. 大数据背景下的用户画像研究综述: 知识体系与研究展望 [J]. 图书馆学研究, 2019(24): 13 - 24.

[6] 宋美琦, 陈烨, 张瑞. 用户画像研究述评 [J]. 情报科学, 2019, 37(4): 171 - 177.

[7] 周光华, 辛英, 张雅洁, 等. 医疗卫生领域大数据应用探讨 [J]. 中国卫生信息管理杂志, 2013, 10(4): 296 - 300.

[8] 张云翔, 张爽. 金融营销领域大数据应用研究 [J]. 特区经济, 2017(5): 78 - 79.

[9] 张淑桂. 大数据分析技术在汽车销售客户分级管理方案中的应用综述 [J]. 电脑知识与技术, 2020, 16(7): 7 - 9.

[10] 代杨, 裴永刚. 基于用户画像的出版企业知识服务商业模式探析 [J]. 中国编辑, 2021(5): 48 - 53.

[11] 刘凯. 基于 K-means 聚类的物流园区用户画像分析 [J]. 物流工程与管理, 2020, 42(3): 52 - 54.

[12] 刘洪辉. 基于公共交通大数据的用户出行行为研究 [D]. 长沙:湖南大学, 2018.

[13] 徐涛, 黄莉, 李敏蕾, 等. 基于多维细粒度行为数据的居民用户画像方法研究 [J]. 电力需求侧管理, 2019, 21(3): 47 - 52.

[14] KIM E-G, CHUN S-H. Analyzing online car reviews using text mining [J]. Sustainability, 2019, 11(6): 1611 - 1633.

[15] 刘海鸥, 刘旭, 姚苏梅, 等. 基于舆情画像的在线社交用户信息传播特征统计分析 [J]. 现代情报, 2019, 39(9): 64 - 73.

[16] 王震飞. 基于 RFM 模型的科学网博客博主群体画像研究——以图书馆学、情报学、档案学三个学科领域为例 [J]. 情报探索, 2020, 7(11): 26 - 33.

[17] 刘燕, 李露琪, 侯丽. 面向知识服务系统的用户画像研究与应用 [J]. 中华医学图书情报杂志, 2020, 29(11): 16 - 23.

[18] 蒋知义, 李巧, 邢思佳, 等. 在线健康社区信息服务质量评价指标体系构建及实证研究 [J]. 情报探索, 2021(4): 29 - 36.

[19] 吴树芳, 吴崇崇, 朱杰. 基于兴趣转移的微博用户动态画像生成 [J]. 情报科学, 2021, 39(8): 103 - 111.

[20] LANZA-CRUZ I, BERLANGA R, ARAMBURU M. Modeling analytical streams for social business intelligence [J]. Informatics-basel, 2018, 5(3): 33 - 50.

[21] 赵岩. 基于数据挖掘技术的消费者购车行为分析 [D]. 呼和浩特:内蒙古工业大学, 2006.

[22] TAYLOR-WEST P, SAKER J, CHAMPION D. Market segmentation strategies for complex automotive products [J]. Journal of strategic marketing, 2020, 28(3): 266 - 283.

[23] 郝淑玲, 米子川, 姜天英. 大数据指数的再定义与新进展 [J]. 统计学报, 2020, 1(4): 1 - 13.

[24] FAYYAD U, PIATETSKY G, PADHRIC S. Knowledge discovery and data mining: towards a unifying framework [C]//Proceedings of second international conference on knowledge discovery and data mining. Palo Alto:AAAI Press, 1996:82 - 88.

[25] KULLBACK S, LEIBLER R. On information and sufficiency [J]. The annals of mathematical statistics, 1951, 22(1): 79 - 86.

[26] KURT W. Kullback-Leibler divergence explained [EB/OL]. [2021 - 09 - 08]. https://www.countbayesie.com/blog/2017/5/9/kullback-leibler-divergence-explained.

[27] WELLS W, TIGERT D. Activities, interests and opinions [J]. Journal of advertising research, 1971, 11(4): 27 - 35.

[28] 马鑫, 段刚龙, 王建仁, 等. 基于改进轮廓系数法的航空公司客户分群研究 [J]. 运筹与管理, 2021, 30(1): 140 - 146.

[29] 黄韬, 刘胜辉, 谭艳娜. 基于 K-means 聚类算法的研究 [J]. 计算机技术与发展, 2011, 21(7): 54 - 57.

[30] KOZAK M. "A dendrite method for cluster analysis" by Caliński and Harabasz: a classical work that is far too often incorrectly cited [J]. Communications in statistics - theory and methods, 2012, 41(12): 2279 - 2280.

[31] 任正东, 章骏腾, 任东晓. 基于目标群体指数的大学生画像分析 [J]. 黑龙江生态工程职业学院学报, 2021, 34(2): 113 - 116.

[32] 何振宇,朱庆华,白玫. 养老服务视角下城市老年人用户画像构建[J]. 情报杂志, 2021,40(9):154 - 160.

Research on User Portrait Model of the Full Data of Search Engines: Design and Empirical Study

Wu Wenhan

Department of Library, Information and Archives, Shanghai University, Shanghai 200444

Abstract: [**Purpose/significance**] This research designs a research model of big data portraits of young users based on 500 million full data of a search engine, including the overall model and detailed research process to establish the basic methodology of user portraits. [**Method/process**] With the combined process of data analysis and data verification, this paper selected representative calculation samples and label samples through KL divergence and AIO sociology model, and used CH-Score and SH-Score to clarify the algorithm and related parameters, used K-Means clustering algorithm and TGI to interpret cluster data. Finally, the association rules were used to discover the young users' car needs. [**Result/conclusion**] This research divides young users 18－24 years old into 5 categories, 25－34 years old into 4 categories, in total of 9 groups, to verify the effectiveness of the model and process. This article completes the methodological establishment of big data user portraits from 0 to 1, and fully integrates research methods and big data methods in it.

Keywords: big data　user portrait　research model

《知识管理论坛》投稿须知

《知识管理论坛》(CN11－6036/C,ISSN 2095－5472)是由中国科学院文献情报中心主办的网络开放获取学术期刊,2017 年入选国际著名的开放获取期刊名录(DOAJ)。《知识管理论坛》致力于推动知识时代知识的创造、组织和有效利用,促进知识管理研究成果的快速、广泛和有效传播。

1. 报道范围

稿件的主题应与知识相关,探讨有关知识管理、知识服务、知识创新等相关问题。稿件可侧重于理论,也可侧重于应用、技术、方法、模型、最佳实践等。

2. 学术道德要求

投稿必须为未公开发表的原创性研究论文,选题与内容具有一定的创新性。引用他人成果,请务必按《著作权法》有关规定指明原作者姓名、作品名称及其来源,在文后参考文献中列出。

本刊使用 CNKI 科技期刊学术不端文献检测系统(AMLC)对来稿进行论文相似度检测,如果稿件存在学术不端行为,一经发现概不录用;若论文在发表后被发现有学术不端行为,我们会对其进行撤稿处理,涉嫌学术不端行为的稿件作者将进入我刊黑名单。

3. 署名与版权问题

作者应该是论文的创意者、实践者或撰稿者,即论文的责任者与著作权拥有者。署名作者的人数和顺序由作者自定,作者文责自负。所有作者要对所提交的稿件进行最后确认。

4. 写作规范

本刊严格执行国家有关标准和规范,投稿请按现行的国家标准及规范撰写;单位采用国际单位制,用相应的规范符号表示。

5. 评审程序

执行严格的三审制,即初审、复审(双盲同行评议)、终审。

6. 发布渠道与形式

稿件主要通过网络发表,如我刊的网站(www.kmf.ac.cn)和我刊授权的数据库。

本刊已授权数据库有中国期刊全文数据库(CNKI)、龙源期刊网、超星期刊域出版平台等,作者稿件一经录用,将同时被该数据库收录,如作者不同意收录,请在投稿时提出声明。

7. 费用

2022 年 2 月 1 日之后的投稿,经审理录用后收取论文处理费 1000 元/篇。

8. 关于开放获取

本刊发表的所有研究论文,其出版版本的 PDF 均须通过本刊网站(www.kmf.ac.cn)在发表后立即实施开放获取,鼓励自存储,基本许可方式为 CC－BY(署名)。详情参阅期刊首页 OA 声明。

9. 选题范围

互联网与知识管理、大数据与知识计算、数据监护与知识组织、实践社区与知识运营、内容管理与知识共享、数据关联与知识图谱、开放创新与知识创造、数据挖掘与知识发现。

10. 关于数据集出版

为方便学术论文数据的管理、共享、存储和重用,近日我们通过中国科学院网络中心的 ScienceDB 平台(www.sciencedb.cn)开通数据出版服务,该平台支持任意格式的数据集提交,欢迎各位作者在投稿的同时提交与论文相关的数据集(稿件提交的第 5 步即进入提交数据集流程)。

11. 投稿途径

本刊唯一投稿途径:登录 www.kmf.ac.cn,点击作者投稿系统,根据提示进行操作即可。